

Leistungsbeschreibung

Datum: 26.03.2024
FKZ: 3723 12 101 0
AZ: 90 460-1/0021

ReFoPlan 2023

Thema: „Data Cube 2.0: Wege in die automatisierte Umweltberichterstattung“

Inhalt

1.	Hintergrund und Problemstellung	2
2.	Ziel und Gegenstand des Forschungsprojekts	3
3.	Aufgabenstellung / Arbeitspakete	3
3.1	Arbeitspaket 1: Datenintegration, Harmonisierung und Verknüpfung	4
3.2	Arbeitspaket 2: Dashboards für die Umweltberichterstattung	6
3.3	Arbeitspaket 3 Anwendung von Methoden des maschinellen Lernens für die Erstellung von Textentwürfen	8
3.4	Arbeitspaket 4: Experimentelle Daten	10
4.	Veranstaltungen	11
4.1	Veranstaltung/Fachtagung/Workshop	11
4.2	Bewirtungskosten	12
4.3	Reisekosten	12
5.	Berichterstattung	13
5.1	Sachstands-/Zwischenberichte	13
5.2	Abschlussbericht	13
5.3	Nutzungsrecht	14
6.	Projektorganisation und Kostendarstellung	14
6.1	Projektorganisation	14
6.2	Kostendarstellung	14
7.	Eignungskriterien	15
8.	Zuschlagskriterien	16

1. Hintergrund und Problemstellung

Mit der Umweltberichterstattung¹ informiert das UBA die allgemeine Öffentlichkeit über den Zustand und wichtige Entwicklungen in der Umwelt. Dabei spielen Daten eine zentrale Rolle, die in verschiedenen Produkten – vor allem über die Webseite – aufbereitet und bereitgestellt werden (siehe www.umweltbundesamt.de/daten).

Mit dem Data Cube – Daten zur Umwelt ([Pilotsystem](#)), der gegenwärtig in einem Projekt entwickelt wird, verfügt das UBA zukünftig über ein leistungsfähiges System, um diese Daten auch maschinenlesbar, in offenen Dateiformaten und über Schnittstellen (API) open-data-konform zur Verfügung zu stellen. Dadurch werden Datenbestände besser verwertbar gemacht und es entstehen auch neue Möglichkeiten für die datenbasierte Kommunikation und eine teil-automatisierte Umweltberichterstattung.

Mit dem Projekt sollen interaktive Formate - wie Dashboards - für verschiedene Zielgruppen und aktuelle Themen entwickelt und für die Umweltberichterstattung fruchtbar gemacht werden. Darüber hinaus soll mit dem Projekt untersucht werden, inwieweit KI-Ansätze bzw. Methoden des maschinellen Lernens zu einer effizienteren und aktuelleren Umweltberichterstattung beitragen können und ob und wie das UBA experimentelle Daten für die Berichterstattung nutzen kann.

Das Vorhaben wird vor dem Hintergrund einer Reihe von Aktivitäten durchgeführt, die derzeit auf nationaler, europäischer und internationaler Ebene stattfinden. Beispielhaft seien hier folgende genannt:

- Die Bundesregierung hat sich mit der Datenstrategie (2021) den Aufbau von Datenräumen zum Ziel gesetzt. Dieses Ziel wurde auch von der gegenwärtigen Bundesregierung im Koalitionsvertrag unterstrichen. Mit der Weiterentwicklung des Data Cubes - Daten zur Umwelt und der offenen Bereitstellung unserer Umweltdaten möchten wir einen Beitrag zur Erreichung dieses Zieles leisten.
- In Merseburg entsteht gegenwärtig das Portal [umwelt.info](#), in dem es zukünftig möglich sein wird, deutschlandweit, von der Ebene der Städte, Gemeinden und Kreise über die Bundesländer bis zum Bund und auch über die verschiedenen Ämter und Behörden und sonstigen Institutionen hinweg, nach aktuellen Umweltdaten zu suchen. Die Daten des Data Cubes werden auch über dieses Portal auffindbar gemacht.
- Im UBA wird darüber hinaus ein Meta-Datenkatalog entwickelt, der einen standardisierten Überblick über die im UBA verfügbaren Datensätze liefern wird. Alle Dataflows des Data Cubes werden hier mit Metadaten beschrieben.
- Seit dem vergangenen Jahr arbeitet das UBA darüber hinaus an einer Datenstrategie, in der die verschiedenen Datenaktivitäten gebündelt und strategisch ausgerichtet werden. Hier liefert der Data Cube einen Beitrag zu verschiedenen Aspekten.
- Unter Federführung des Bundeskanzleramtes hat die Bundesregierung den 4. Aktionsplan Open Government im Rahmen der Open Government Partnership verabschiedet. In den jeweiligen Aktionsplänen verpflichtet sich die

¹ Unter „Umweltberichterstattung“ sind hier die Inhalte der verschiedenen Elemente (Artikel, Diagramme, Infografiken, Karten und sonstige Formate) zu verstehen, die über die Webseite des UBA im Bereich „Daten“ veröffentlicht werden.

Bundesregierung zur Umsetzung verschiedener Maßnahmen, die das offene Regierungshandeln in Deutschland voranbringen sollen. Das Projekt Data Cube wurde als Verpflichtung für den 4. Aktionsplan aufgenommen.

2. Ziel und Gegenstand des Forschungsprojekts

Mit dem Projekt soll zum einen der entstehende Data Cube des Umweltbundesamtes inhaltlich und funktionell weiterentwickelt werden, zum anderen sollen Ansätze des maschinellen Lernens und experimentelle Datenquellen für die Umweltberichterstattung fruchtbar gemacht werden.

Im Einzelnen werden folgende Ziele mit dem Projekt verfolgt:

- AP 1 (Datenintegration und Harmonisierung): Es sind weitere Datensätze in den Data Cube aufzunehmen und die entsprechenden ETL-Prozesse zu erarbeiten. Bestehende und zukünftige Datensätze sollen stärker miteinander verzahnt und die Dimensionen des Data Cubes weiter harmonisiert werden. Bestehende und zukünftige Dataflows sollen zudem in den Standard SDMX 3.0 überführt und die entsprechenden ETL Prozesse auf SDMX 3.0 angepasst werden.
- AP 2 (Dashboards): Es ist ein neues Format für Dashboards zu entwickeln und in die UBA-Webseite zu integrieren. Dafür soll ein Co-Design Workshop im UBA durchgeführt werden. Im Anschluss erarbeitet der Auftragnehmer ein inhaltliches, technisches und graphisches Konzept für das Format Dashboard, entwickelt die technische Basis, integriert diese in die UBA-Webseite und setzt das neue Format für drei Themen um.
- AP 3 (Maschinelles Lernen): Im Rahmen dieses Arbeitspaketes soll geprüft werden, inwieweit Methoden des maschinellen Lernens genutzt werden können, um Inhalte für die UBA-Webseite zu erzeugen. Dafür ist ein Tool zu entwickeln, das es ermöglicht bestimmte Texte automatisiert zu aktualisieren, sobald neue Daten vorliegen.
- AP 4 (Experimentelle Daten): In diesem Arbeitspaket sollen Ideen für innovative Datenquellen und Methoden recherchiert und bewertet werden. Auf der Grundlage dieser Vorarbeiten sind vom Auftragnehmer drei Projektskizzen für experimentelle Datenprojekte zu entwickeln.

3

3. Aufgabenstellung / Arbeitspakete

Technischer Hintergrund

Mit dem Projekt Konzeptstudie UNIS-D – Teilprojekt 2 Data Cube (FKZ: 3720 12 101 0) wurde ein performantes System zur Bereitstellung, Visualisierung, Analyse und Aufbereitung von statistischen Umweltdaten für das UBA entwickelt. Der Data Cube besteht aus den nachfolgenden Komponenten.

Dateninput: die Integration neuer Daten und Aktualisierung bestehender Datensätze erfolgt gegenwärtig durch ETL-Prozesse auf Basis der Software FME (Desktop und Server). Die Datenstrukturen für neue Dataflows werden über csv Dateien in einem Git-Repository und über automatisierte ETL-Prozesse erzeugt. Im Ergebnis entstehen so SDMX-Artefakte der jeweiligen Datenstrukturen sowie die eigentlichen Datensätze mit den fachlichen Beobachtungen. Sowohl Strukturen als auch Datensätze werden im Anschluss in den Data Lifecycle Manager der .Stat Suite (siehe nächster Abschnitt) geladen und dort verwaltet.

Datenhaltung und Visualisierung: Als zentrales System des Data Cubes wird die Open Source Software .Stat Suite verwendet. Die .Stat Suite besteht unter anderem aus den Komponenten Data Explorer (zur Suche, Visualisierung und Bereitstellung der Daten) und Data Lifecycle Manager (zur Verwaltung der Datenstrukturen). Der Data Explorer ermöglicht unter anderem die Visualisierung und den Download der im Data Cube enthaltenen Daten im Excel- bzw. CSV-Format sowie die Datenabfrage über eine REST-API.

Hinweis:

Informationen zur .Stat Suite Software und deren Nutzung finden Sie hier:

- (1) Überblick über die .Stat Community: <https://siscc.org/stat-suite/>
- (2) Ausführliche technische Dokumentation: <https://sis-cc.gitlab.io/dotstatsuite-documentation/>
- (3) Software und Quellcode und alle zur .Stat Suite gehörenden Repositorien: <https://gitlab.com/sis-cc/.stat-suite>).
- (4) Demoversion der .Stat Suite: [Demo .Stat Data Explorer \(siscc.org\)](#)

Einbettung in die UBA-Webseite: Die Einbettung und Visualisierung der Datensätze auf der UBA-Webseite erfolgt mittels der Java Script Bibliothek Higcharts. Die Daten des Data Cubes können durch eine Weiterentwicklung des Drupal Moduls Easychart direkt im CMS der UBA-Webseite konfiguriert, gestaltet und an verschiedenen Stellen der UBA-Webseite bereitgestellt werden.

SDMX: SDMX steht für Statistical Data and Metadata eXchange und ist ein ISO Standard, der entwickelt wurde um statistische Daten und Metadaten zu beschreiben und standardisiert auszutauschen. Der Standard bietet einen integrierten Ansatz um statistische Daten und Metadaten interoperabel innerhalb und zwischen verschiedenen Systemen auszutauschen und wird von vielen (internationalen) Organisationen verwendet (z.B. Eurostat, EZB, OECD). Weitere Informationen finden sich auf der Webseite: www.sdmx.org.

3.1 Arbeitspaket 1: Datenintegration, Harmonisierung und Verknüpfung

Innerhalb von AP1 sollen insbesondere die folgenden Arbeiten durchgeführt werden:

(1) Es sollen weitere Datenquellen an den Data Cube angebunden werden; (2) der Auftragnehmer soll das UBA darin unterstützen, Datensätze stärker miteinander und mit weiteren UBA-Datenquellen zu verzahnen und mit qualitativ hochwertigen Metadaten zu beschreiben und (3) die neuen und zukünftigen Dataflows, sowie die dazugehörigen ETL-Prozesse sind auf die SDMX Version 3.0 anzupassen.

Da aus heutiger Sicht noch nicht abschließend beurteilt werden kann, wann einzelne Arbeiten von AP1 durchgeführt werden können (z.B. wann die jeweiligen Ausgangsdaten für neue Dataflows vorliegen bzw. wann SDMX 3.0 auch für die .Stat Suite verfügbar sein wird), ist AP1 so zu konzipieren, dass das Arbeitspaket über die gesamte Projektlaufzeit bearbeitet wird.

Zu (1): Im Projekt sollen insgesamt ca. 50 Dataflows in den UBA Data Cube integriert werden (im Durchschnitt kann dafür im Angebot ein Aufwand von ca. 1 ½ Personentage pro Dataflow angenommen werden). Ein Dataflow umfasst im Ergebnis einen konsistenten Datensatz, der mit Dimensionen und Attributen beschrieben werden kann. Der Auftragnehmer soll das UBA darin unterstützen neue Datenquellen auszuwählen und die Daten für den Data Cube zu modellieren. Dazu gehört die Sichtung der ursprünglichen Datenquellen, die Aufteilung der Daten in einzelne Dataflows, die Beschreibung der Datensätze mit geeigneten Dimensionen und Attributen und die (teil-) automatisierte Erzeugung entsprechender Codelisten und Hierarchien sowie der entsprechenden SDMX-Artefakte (Data Structure Definitions, Dataflows, Concept-Schemes, Codelisten). Die Modellierung beinhaltet ausdrücklich auch die fachliche Auseinandersetzung mit den Daten und benötigt entsprechende Kenntnisse der Umweltstatistik. Darüber hinaus müssen für alle zu integrierenden Daten ETL-Prozesse auf Basis einer geeigneten Programmiersprache (z.B. Python oder Rust) oder FME Form, bzw. Flow erarbeitet werden. Alle strukturellen und referentiellen Metadaten sowie die erarbeiteten ETL-Prozesse (im Quellcode) müssen vom Auftragnehmer sowohl auf Deutsch als auch auf Englisch bereitgestellt werden.

5

Zu (2): Die im Data Cube enthaltenen Datensätze enthalten verschiedene Querbezüge untereinander und zu weiteren Datenquellen innerhalb und außerhalb des UBA. Im Rahmen des Vorhabens soll der Auftragnehmer die Datenquellen sichten, mögliche Querbezüge herausarbeiten und die Datensätze – zum Beispiel über Metadaten oder direkte Verlinkungen stärker miteinander in Beziehung setzen. Die Datenstrukturen (Dimensionen und Attribute) des Data Cubes werden über Codelisten verwaltet und abgebildet. Im Zuge dieser Verknüpfung ist vom Auftragnehmer – auch fachlich - zu prüfen, inwieweit die bestehenden Codelisten weiter harmonisiert werden können.

Zum Beispiel sollen mit Bezug auf räumliche Darstellungsmöglichkeiten die dafür geeigneten Dataflows nach Möglichkeit mit entsprechenden Geodaten (die z.B. in der UBA-Geodateninfrastruktur vorgehalten werden können) oder über die Beschreibung der Metadaten verknüpft werden. Ein Beispiel hierfür sind die Daten der anlagenbezogenen Berichterstattung, in denen nicht nur die jeweiligen Emissionen, sondern auch die Koordinaten der Anlagen enthalten sind. Für die Verknüpfungsmöglichkeiten sollen die erweiterten Möglichkeiten der SDMX Version 3.0 zur Darstellung von Geodaten untersucht und genutzt werden (siehe nächster Abschnitt).

Zu (3): Die für den Data Cube eingesetzte Software .Stat Suite unterstützt gegenwärtig den SDMX Standard in der Version 2.1. Im Jahre 2021 wurde der SDMX-Standard allerdings bereits in der Version 3.0 veröffentlicht ([siehe hier](#)). Diese Version soll – nach Informationen der .Stat Community - innerhalb der Projektlaufzeit auch von der .Stat Suite unterstützt werden. Im Rahmen des Projektes hat der Auftragnehmer die bestehenden und zukünftigen Dataflows und die dazugehörigen ETL-Prozesse auf diese neue SDMX-Version umzustellen. Die neuen Möglichkeiten und Potentiale von SDMX 3.0 im Rahmen der .Stat Suite sollen darüber hinaus in einem kurzen Papier dargestellt werden.

Zwischenbericht: Die Ergebnisse des Arbeitspaketes sind in einem Zwischenbericht zu dokumentieren.

Ergebnisse von AP 1:

- Erstellung und Integration von ca. 50 weiteren Dataflows für den UBA Data Cube und entsprechende ETL Prozesse
- Angereicherte Datensätze und Querverbindungen, insbesondere in Bezug auf die Metadaten und Verknüpfung zum Bereich Geodaten sowie Harmonisierung der Codelisten
- Upgrade der bestehenden Datensätze und der dazugehörigen Transformationen auf SDMX 3.0 und kurzes Papier (4-5 Seiten) zu dadurch entstandenen neuen Möglichkeiten für die Berichterstattung
- Zwischenbericht zu AP 1

6

3.2 Arbeitspaket 2: Dashboards für die Umweltberichterstattung

Im Rahmen der Umweltberichterstattung ist das UBA verpflichtet, aktuelle Umweltdaten zu veröffentlichen. Dafür bieten sich insbesondere interaktive Formate an, die kontinuierlich aktualisiert werden können und es den Nutzerinnen und Nutzern erlauben, komplexere Datensätze ansprechend und zugänglich aufzubereiten. In Arbeitspaket 3 soll auf der Grundlage der Daten aus dem Data Cube ein Dashboard-Format für die Webseite des Umweltbundesamtes entwickelt und lauffähig integriert werden. Mit dem Dashboard sollen die Mitarbeitenden des UBA in die Lage versetzt werden, schnell und ohne externe Unterstützung grafisch ansprechende Dashboards zur kommunikativen Unterstützung wichtiger politischer Prozesse zu veröffentlichen.

Zunächst soll der Auftragnehmer ein inhaltliches und technisches Konzept für das Format „Dashboard“ erstellen und mit dem UBA abstimmen. Das Dashboard-Konzept soll nutzerzentriert entwickelt werden. Dafür ist ein eintägiger Co-Design Workshop mit dem Auftraggeber (UBA/BMUV und externen Teilnehmenden) zu organisieren und durchzuführen.

Im Konzept müssen mindestens die folgenden Themen abgebildet werden:

- Inhaltliches Konzept: Im Konzept soll insgesamt der Frage nachgegangen werden, wofür Dashboards im UBA eingesetzt werden können und sollten? Dabei sollen der Forschungsnehmer mit verschiedenen Kommunikationszielen

auseinandersetzen, Vorschläge machen für geeignete Themen (inkl. Datenrecherche und Anforderungen an die Daten), sich mit verschiedenen Zielgruppen auseinandersetzen und dabei auch der Frage nachgehen, wen man mit einem Dashboard eher nicht erreicht. Das Konzept soll weiterhin aufzeigen, welche Funktionen für welche Zielgruppe sinnvoll sind und wo und wie Dashboards in die UBA-Webseite sinnvoll integriert werden sollten. Abschließend sollen im Konzept Vorschläge für eine flexible Struktur gemacht werden, in der je nach Thema verschiedene Funktionen und weitere Informationen eines Dashboards abgebildet und z.B. mit Presseaktivitäten des UBA verzahnt werden können.

- Designkonzept: Entwicklung eines Designkonzeptes für Dashboards. Vorschläge für innovative Datenvisualisierungen (innovative Arten von Diagrammen und Infografiken etc.) unter Berücksichtigung des UBA Corporate Designs. Im Designkonzept sollen Vorschläge für die Navigation, das Interface Design und die Gliederung und den Gesamtaufbau der Seite gemacht werden. Die Anforderungen der Barrierefreiheit sind dabei bereits zu berücksichtigen.
- Technisches Konzept: Welche Funktionen sollte das Dashboard-Format enthalten? Wie kann die Integration in die UBA-Webseite vollzogen werden (z.B. neuer Inhaltstyp für Drupal)? Der Auftragnehmer soll prüfen, inwieweit ein bestehendes Produkt (vorzugsweise Open Source) für die Erstellung verwendet werden kann. Weitere Fragen mit Blick auf das technische Konzept sind: Wie kann die Verknüpfung mit dem Data Explorer des Data Cube des UBA erfolgen (siehe technischer Hintergrund)? Wie können Datenquellen, die nicht im UBA vorliegen angebunden werden (ggf. in Echtzeit)? Wie kann die Verknüpfung mit Geodaten aus Geodateninfrastruktur des UBA erfolgen?

7

Im zweiten Schritt soll das Konzept für die UBA-Webseite technisch umgesetzt werden. Dazu sollen geeignete Tools ausgewählt und ggf. weiterentwickelt werden. Bereits jetzt können Datensätze über die API des Data Explorer abgerufen und mittels der Komponente Easychart auf Basis der Bibliothek Highcharts auf der Webseite visualisiert werden. Im Rahmen dieses Arbeitspaketes sollen diese Funktionalitäten weiterentwickelt und auch durch die Verwendung weiterer Tools (z.B. Tableau, als ShinyApp etc.) weiter ausgebaut werden.

Nach der Entwicklung der technischen Grundfunktionalitäten sind vom Auftragnehmer drei Dashboards inhaltlich auszuarbeiten und technisch umzusetzen. Die Themen für die jeweiligen Dashboards können erst im Projektverlauf vom Auftraggeber entschieden werden. Ziel der Dashboards ist es, politisch besonders relevante Prozesse kommunikativ zu unterstützen.

Zwischenbericht: Die Ergebnisse des Arbeitspaketes sind in einem Zwischenbericht zu dokumentieren.

Vorschläge für die Struktur des Dashboard-Konzeptes und die Vision des Anbieters sollen bereits im Angebot skizziert werden.

Ergebnisse von AP 2:

- Konzeption, Organisation und Durchführung eines Co-Design Workshop im UBA (ganztätig, 15 Teilnehmer*innen)
- Inhaltliches, technisches und Design-Konzept für das Format Dashboards
- Technische Entwicklung und Implementierung einer graphisch ansprechenden Dashboard-Funktion für die UBA-Webseite
- 3 Dashboards zu ausgewählten Themen
- Zwischenbericht zu AP 2

3.3 Arbeitspaket 3 Anwendung von Methoden des maschinellen Lernens für die Erstellung von Textentwürfen

KI-Modelle bzw. Modelle des maschinellen Lernens zur Erstellung von Texten haben in den vergangenen Jahren große Fortschritte gemacht und nicht erst seit der Veröffentlichung von Chatbots – wie ChatGPT auf Basis des Sprachmodells GPT-3.5 bzw. 4.0 – große öffentliche Aufmerksamkeit erfahren. Solche *Natural Language Processing (NLP)*, bzw. *Natural Language Generation (NLG)* – Modelle werden bereits vielfältig zur automatisierten Erzeugung von Texten eingesetzt.

Im Rahmen der Umweltberichterstattung des Umweltbundesamtes informiert das UBA die allgemeine Öffentlichkeit über aktuelle Daten, Trends und Bewertungen zur Umweltsituation in Deutschland. Die aufbereiteten Informationen werden in verschiedenen Produkten (Artikeln, Indikatoren, Broschüren etc.) über die Webseite des Umweltbundesamtes verbreitet und regelmäßig auf der Grundlage neuerer Erkenntnisse und Daten aktualisiert (vgl. <https://www.umweltbundesamt.de/daten>).

8

In Arbeitspaket 3 ist ein Konzept zu entwickeln, anschließend technisch umzusetzen und zu evaluieren, wie datenbasierte UBA-Texte bzw. Teile davon, zukünftig mit Hilfe des maschinellen Lernens „automatisiert“ aktualisiert werden können, wenn neue Daten vorliegen. Bei den Texten geht es insbesondere um Textabschnitte, in denen die Entwicklung bestimmter Indikatoren oder sonstiger Umweltdaten dargestellt wird. Der Auftragnehmer kann hier die Texte der UBA-Indikatoren ([Übersicht der Indikatoren](#), [Beispiel Text eines einzelnen Indikators](#)) als Referenz für das Projekt ansehen. Die fachliche Prüfung dieser maschinell erzeugten Textentwürfe soll dabei auch in Zukunft in der Verantwortung der fachlich zuständigen Mitarbeiter*innen des UBA liegen.

Konzeption:

In einem ersten Schritt ist vom Auftragnehmer ein Konzept eines solchen Ansatzes zu entwickeln. Dabei sollen u.a. die folgenden Themen und Fragestellungen behandelt werden:

1. Analyse der Umweltberichterstattung (welche Textteile/Produkte sind potentiell geeignet);
2. Übersicht über relevante Modelle zur Texterzeugung, insbesondere mit Fokus auf die Aktualisierung von datenbasierten Texten;
3. Begründete Auswahl eines NLP/NLG-Modelles für die hier beschriebene Zielsetzung;
4. Beschreibung konkreter Anwendungsfälle und möglicher Workflows;

5. Technische Konzeption für die lauffähige Integration in die IT-Umgebung des UBA;
6. Kosten-Nutzen-Bewertung des vorgeschlagenen Ansatzes (in diesem Abschnitt sollten neben den Vorteilen auch die möglichen Nachteile (z.B. unangemessene Sprache, mögliche falsche Behauptungen, fehlende Quellen) und Herausforderungen (deutsche Grammatik, Zeichensetzung), eine juristische Einschätzung zum Einsatz solcher Methoden als Bundesbehörde und mögliche Lösungsansätze für die damit einhergehenden Probleme dargestellt werden.

Workshop:

Der Auftragnehmer soll den erarbeiteten Konzept-Entwurf im Anschluss in einem ganztägigen Workshop im UBA (unter Beteiligung verschiedener Akteure, z.B. Mitarbeitende des KI-Anwendungslabors des UBA) vorstellen und mit den Teilnehmenden diskutieren. Nach dem Workshop soll das Konzept vor dem Hintergrund der im Workshop gewonnenen Erkenntnisse finalisiert werden. Aus dem Konzept sollte klar hervorgehen, welche Texte bzw. Text-Typen des UBA für die automatisierte Aktualisierung geeignet erscheinen, welches Modell dafür genutzt werden soll, welche Risiken und Chancen und Kosten mit dem Einsatz eines solchen Modells einhergehen, wie die Qualitätsprüfung erfolgt und wie der Ansatz im UBA technisch implementiert werden kann.

Technische Umsetzung:

In Rücksprache mit dem Auftraggeber ist das Konzept bzw. der gewählte Ansatz im Anschluss umzusetzen und fertig zu entwickeln. Im Ergebnis soll ein Tool entstehen, mit dem die Redakteurinnen und Redakteure der UBA-Webseite automatisiert aktualisierte Texte bzw. Textabschnitte auf der Grundlage neuer Daten erzeugen können. Das Tool soll die Möglichkeit bieten in einer graphischen Oberfläche die Textvorschläge zu prüfen, zu ändern oder zu verwerfen. Dabei sollen die, durch das Tool veränderten Textstellen, kenntlich gemacht werden. Der Workflow zur Erzeugung der neuen Texte soll nutzerzentriert erarbeitet und möglichst reibungslos mit dem bisherigen Workflow bei der Aktualisierung von Webinhalten für die Daten zur Umwelt verzahnt werden. Als Dateninput für den Prozess kann davon ausgegangen werden, dass die aktualisierten Daten über die API des Data Cubes abgerufen werden können. Ggf. anfallende Lizenzkosten für die Nutzung eines KI-Modells sind vom Anbieter für die 6-monatige Testlaufzeit pauschal auf der Grundlage aktuell üblicher Preise zu kalkulieren und im Angebot auszuweisen.

Evaluation:

Das neu erarbeitete Tool soll anschließend in einer 6-monatigen Testphase innerhalb der Projektlaufzeit von den Redakteurinnen und Redakteuren des UBA getestet und evaluiert werden. Diese Evaluationsphase ist vom Auftragnehmer durch geeignete Instrumente (z.B. Befragungen etc.) zu begleiten. Zum Ende der Evaluationsphase ist ein Workshop mit den Nutzer*innen des Tools durchzuführen, die Ergebnisse sind zu dokumentieren. Konzeption, Organisation, Durchführung und Dokumentation obliegen dem Auftragnehmer.

Zwischenbericht: Die Ergebnisse (Konzept, Dokumentation des Tools und Evaluation) sind in einem Zwischenbericht aufzubereiten.

Eine erste Auseinandersetzung mit den Potentialen, Chancen und Risiken des hier dargestellten Ansatzes sollte bereits aus dem Angebot hervorgehen.

Ergebnisse von AP 3:

- Konzept für die automatisierte Erzeugung von Texten für die UBA-Webseite
- Konzept-Entwurf Workshop Konzeption und Dokumentation im UBA (ganztägig, 20 Teilnehmer*innen)
- Funktionsfähiges und im UBA lauffähiges Tool
- Evaluation Workshop und Dokumentation im UBA (ganztägig, 20 Teilnehmer*innen)
- Zwischenbericht zu AP 3

3.4 Arbeitspaket 4: Experimentelle Daten

Im Zuge der Digitalisierung sind auch die potentiell verfügbaren Datenquellen und Methoden für deren Auswertung rasant gestiegen. Um ihren jeweiligen gesetzlichen Auftrag zu erfüllen, haben sich daher auch die statistischen Ämter weiterentwickelt und erkunden zunehmend die Möglichkeiten eher experimentelle Daten zu nutzen (vgl.: [Experimentelle Daten des Statistischen Bundesamtes](#)). Experimentelle Daten meint hier, dass die Datenqualität (noch) nicht dem eigentlich notwendigen Reifegrad für die amtliche Statistik entspricht. Gleichwohl und im Sinne der Transparenz, werden diese Machbarkeitsstudien mit experimentellen Daten bereits veröffentlicht, bevor sie gegebenenfalls Verwendung in der amtlichen Statistik finden können.

10

Dieses Vorgehen ist auch für die Umweltberichterstattung interessant. Mit dem Ziel zeitlich und räumlich hochaufgelöste Umweltdaten zur Verfügung stellen zu können, sollen im Rahmen dieses Arbeitspaketes innovative Datenquellen und Methoden für die Umweltberichterstattung recherchiert und aufbereitet und in konkrete Projektskizzen überführt werden.

Nach einer grundsätzlichen Auseinandersetzung mit der Umweltberichterstattung des UBA und deren Datenquellen sind in einem ersten Schritt mögliche Datenquellen jenseits der amtlichen Statistik bzw. der bestehenden konventionellen Datenquellen zu recherchieren und hinsichtlich ihrer fachlichen, juristischen und technischen Nutzbarkeit für die Umweltberichterstattung zu bewerten. Der Auftragnehmer soll bei der Recherche kreativ und mutig vorgehen und auch Datenquellen in den Blick nehmen, deren Umwelrelevanz nicht unmittelbar ersichtlich ist und die als Proxy-Indikator verwendet werden können (natürlich nur, sofern diese vom Auftragnehmer plausibel hergeleitet werden kann). Die Ergebnisse sind in einem Input-Papier für einen Workshop (siehe weiter unten) aufzubereiten.

Neben den Datenquellen haben sich auch die Methoden zur Datenanalyse kontinuierlich weiterentwickelt. Eine besondere Rolle spielen hierbei Ansätze des maschinellen Lernens, die ggf. auch in Verbindung mit klassischen statistischen Verfahren neue Möglichkeiten der Datenauswertung ermöglichen. Der Auftragnehmer soll in einem weiteren Input-Papier einen Überblick über wichtige Trends- und Entwicklungen im

Bereich der Datenanalyse in den vergangenen fünf Jahren geben. Dabei sollen insbesondere solcher Ansätze dargestellt werden, die zusammen mit den innovativen Datenquellen, dazu geeignet sind, die zeitliche und räumliche Auflösung und die Datenaktualität (z.B. Nowcasting) der bestehenden Umweltdaten zu verbessern.

Im Anschluss an die Erarbeitung der beiden Input-Papiere soll der Auftragnehmer einen ganztägigen Ideenfindungsworkshop (z.B. im Co-Design-Format) konzipieren, organisieren und durchführen. Dabei sollen vor dem Hintergrund der beiden Input-Papiere Ideen für Forschungsprojekte entwickelt werden. Welche Fachexpertinnen*Fachexperten aus dem UBA und welche externen Teilnehmenden, zum Workshop eingeladen werden, kann erst entschieden werden, wenn klar geworden ist, welche Themenschwerpunkte sich in den beiden Input-Papieren als vielversprechend herauskristallisiert haben. Die Ergebnisse sind im Anschluss in einer Workshop-Dokumentation festzuhalten.

Nach Rücksprache mit Auftraggeber (und in Rücksprache mit den betroffenen Fachgebieten im UBA) sind im Anschluss 3 Projektideen auszuarbeiten. Der Auftragnehmer soll auch hier eigenständig, kreativ und mutig vorgehen. Die mit der Verwendung von innovativen Datenquellen einhergehende fachliche Unsicherheit bezüglich der Datenqualität soll abgeschätzt werden und es sind Vorschläge für die Kommunikation dieser Unsicherheit darzustellen. Die entstehenden Projektskizzen sollen einen Umfang von jeweils 4-5 Seiten haben.

Zwischenbericht: Die Ergebnisse sind in einem Zwischenbericht aufzubereiten.

Erste Ideen für mögliche experimentelle Datenprojekte sollen bereits im Angebot dargestellt werden.

Ergebnisse von AP 4:

- Input-Papier zu innovativen Datenquellen
- Input-Papier zu innovativen Ansätzen zur Datenanalyse
- Workshop im UBA (ganztägig, 20 Teilnehmer*innen)
- 3 Projektskizzen im Umfang von 4-5 Seiten.
- Zwischenbericht zu AP 4

4. Veranstaltungen

4.1 Veranstaltung/Fachtagung/Workshop

Der Auftragnehmer ist verantwortlich für die Planung, Vorbereitung (inklusive Einladung u. Teilnehmermanagement), Durchführung, Nachbereitung und schriftliche Protokollierung der Projekttreffen, Telefonkonferenzen, Workshops, Vorträge und des Fachgesprächs.

Er erstellt einen Projektplan und stimmt die Meilensteine (thematisch und zeitlich) mit dem Auftraggeber am Anfang des Projekts ab.

Zum Beginn des Forschungsvorhabens ist ein Projektauftrittsgespräch mit den zuständigen Fachleuten aus dem Umweltbundesamt und dem BMUV in Dessau-Roßlau vorzusehen. Außerdem sind acht regelmäßige Projekttreffen zur Klärung fachlicher und organisatorischer einzuplanen. Drei der acht Projekttreffen sind als Präsenztermine in Dessau oder Berlin zu planen, die anderen fünf Projekttreffen können virtuell durchgeführt werden. Zum Ende des Vorhabens sollen die Auftragnehmer die Projektergebnisse in einem halbtägigen Fachgespräch vorzustellen. Das Projektauftrittsgespräch und das abschließende Fachgespräch sind jeweils als Präsenzveranstaltungen zu kalkulieren.

Zusätzlich zum Auftaktgespräch, den acht Projekttreffen und dem abschließenden Fachgespräch sind darüber hinaus insgesamt vier Workshops im Angebot vorzusehen (siehe AP 2, AP 3 und AP 4).

Vom Umweltbundesamt wird eine Fachbegleitung als zentrale und verantwortliche Ansprechperson benannt. Vorbereitende Unterlagen für alle Projekttreffen und Workshops sind der Fachbegleitung rechtzeitig, das heißt spätestens eine Woche vor dem jeweiligen Besprechungstermin, zu übermitteln. Protokolle sind innerhalb von zwei Wochen mit der Fachbegleitung abzustimmen und an die beteiligten Personen zu versenden.

Sachstandsberichte (Quartalsweise)

Zu Dokumentationszwecken sind quartalsweise Sachstandsberichte zu erstellen. Diese sollten einen Umfang von ca. 4 Seiten haben und den Projektfortschritt dokumentieren.

12

4.2 Bewirtungskosten

Die Bewirtungskosten dürfen maximal einen Wert in Höhe von 10,00€ brutto (8,40€ netto/19% bzw. 9,35€ netto/7%) pro Ganztagsveranstaltung p. P. (bei halbtägigen Sitzungen bis zu maximal 5,00€ brutto (4,20€ netto/19% bzw. 4,67€ netto/7%)) betragen. Hierbei sind Erfrischungsgetränke für die Teilnehmerinnen und Teilnehmer vorgesehen. Projektbesprechungen zwischen dem Auftragnehmer und Auftraggeber sind davon ausgeschlossen. Für die im Vorhaben geplanten vier Workshops sind entsprechende Bewirtungskosten im Angebot zu kalkulieren.

4.3 Reisekosten

Reisekosten sind einzeln im Angebot auszuweisen (Bahnfahrt 2. Klasse bzw. bei einer Reisezeit von über 2 Stunden können auch die Reisekosten für eine Bahnfahrt 1. Klasse anerkannt werden). Bahnreisen sind immer bevorzugt zu wählen, auch wenn dadurch höhere Kosten, wie z.B. einer zusätzlichen Übernachtung, entstehen. Das Bundesreisekostengesetz (BRKG) ist zu beachten.

Bei Veranstaltungen können die Räume des UBA oder des BMUV kostenfrei genutzt werden. Honorare oder Reisekosten für externe Teilnehmerinnen und Teilnehmer sind hierbei nicht vorzusehen.

5. Berichterstattung

5.1 Sachstands-/Zwischenberichte

Nach 8 Monaten (Arbeitspaket 1), nach 16 Monaten (Arbeitspaket 2), nach 24 Monaten (Arbeitspakete 3) und nach 28 Monaten (Arbeitspaket 4) legt der Auftragnehmer Entwürfe der Zwischenberichte vor. Diese beinhalten die bisherigen Arbeiten zu den einzelnen Arbeitspaketen. Sofern einzelne Arbeitspakete zu diesen Zeitpunkten noch nicht abgeschlossen werden konnten (siehe zeitlicher Bearbeitungshinweis zu AP 1) beinhalten die Zwischenberichte den jeweiligen Arbeitsstand mit einem der Zeitplanung entsprechenden Arbeitsfortschritt. Die vollständigen Zwischenberichte sind dann nach Abschluss der jeweiligen Arbeitspakete vorzulegen.

Quartalsweise legt der Auftragnehmer darüber hinaus den Projektfortschritt in kurzen Sachstandsberichten dar (siehe 4.1).

5.2 Abschlussbericht

Der Entwurf des Schlussberichts ist 3 Monate vor Ende des Vorhabens in deutscher Sprache als Worddokument bei der zuständigen Fachbegleitung einzureichen.

Im Schlussbericht ist auch eine 10-15-seitige Zusammenfassung in englischer und deutscher Sprache zu erstellen. Die mit der Zuschlagserteilung zur Verfügung gestellte Vorlage ist entsprechend zu nutzen.

Die sprachliche Qualitätssicherung obliegt dem Forschungsnehmer. Dies bedeutet u. a., dass sicherzustellen ist, dass durchgängig geschlechtergerechte Sprache verwendet wird.

Der Abschlussbericht sowie alle darüber hinaus für die Veröffentlichung vorgesehenen Publikationen sind gemäß den Designvorgaben des Umweltbundesamtes (Corporate Design Handbuch, Dokumentvorlagen, Diagrammvorlagen etc.) und gemäß des Behindertengleichstellungsgesetzes (BGG) barrierefrei zu gestalten.

Die Erzeugung und Bearbeitung der finalen PDF soll erst nach Freigabe der Worddatei durch die UBA-Fachbegleitung erfolgen. Je nach Art und Umfang der Inhalte ist es sehr aufwändig, eine Veröffentlichung mit komplexen Strukturen, umfangreichen Tabellen, Fußnoten, Grafiken oder Formeln durchgängig barrierefrei zu erstellen. Es sind dafür neben konzeptionellen Vorüberlegungen viele manuelle Arbeitsschritte notwendig, die sich teilweise durch kostenpflichtige Programme vereinfachen lassen. Besteht seitens des Auftragnehmers keine oder nur wenig Erfahrung, sind für die technische Umsetzung des Endproduktes nicht nur ausreichend Zeit und Aufwand, sondern eventuell auch zusätzliche Kosten einzuplanen. Alternativ ist ein entsprechend erfahrener Dienstleister mit der Aufgabe zu betrauen. Um die Barrierefreiheit der gelieferten PDF-Dokumente nachzuweisen, sind Prüfprotokolle einzureichen, die durch die Dokumentenprüfung mit der jeweils aktuellsten Version des PDF Accessibility Checkers (als Freeware im Internet verfügbar) erzeugt wurden. Der Abschlussbericht und die sonstigen gelieferten PDF-Dokumente können erst dann abgenommen werden, wenn das Prüfprotokoll keine Fehler und Warnungen anzeigt. In der Regel muss der PAC-Prüfbericht daher mit einem

grünen Häkchen als bestanden gekennzeichnet sein. Weitere Informationen und Erläuterungen finden Sie unter www.umweltbundesamt.de/dokumentvorlagen.

Die inhaltliche sowie formelle Überarbeitung des Schlussberichtes (und ggf. weiterer Dokumente, die für eine Veröffentlichung vorgesehen sind) sind im Angebot zu berücksichtigen.

Der Schlussbericht ist elektronisch als Worddokument und als PDF vorzulegen.

Sofern Berichte, Broschüren, Flyer für Veranstaltungen und weitere Druckerzeugnisse in größerer Stückzahl bei einer Druckerei in Auftrag gegeben werden, sind diese nach den Vergabekriterien des Blauen Engel für Druckerzeugnisse DE-UZ 195 herzustellen. Auf der Homepage: <https://www.blauer-engel.de/de/produktwelt/papier-druck/print-houses-and-printed-matters> sind die Vergabekriterien und die Druckereien, die einen Zeichennutzungsvertrag für die Herstellung von Druckerzeugnissen mit dem Blauen Engel innehaben, abrufbar.

5.3 Nutzungsrecht

Der Auftragnehmer räumt dem Auftraggeber gemäß § 31 Urheberrechtsgesetz (UrhG) unter Ausschluss der Vorbehalte des § 37 UrhG ein unwiderrufliches, unentgeltliches und nichtausschließliches Nutzungsrecht am Ergebnis und allen Teilergebnissen ein.

Für Berichte, die Grafiken und Bilder enthalten, ist die Erklärung erforderlich, dass die Nutzung der Grafiken und Bilder honorarfrei ist und keine weiteren Kosten für Rechte Dritter entstehen.

Alle im Projekt entwickelten Softwarekomponenten sind Open Source unter einer offenen Lizenz zur Verfügung zu stellen. Nach Möglichkeit soll dafür die Plattform opencode.de genutzt werden.

14

6. Projektorganisation und Kostendarstellung

6.1 Projektorganisation

Das Vorhaben beginnt unmittelbar nach Zuschlagserteilung. Die Laufzeit des Vorhabens beträgt 34 Monate.

Die Arbeiten sind in enger Abstimmung und Rückkopplung mit dem Auftraggeber (Fachseite) zu erledigen.

Der Auftragnehmer hat für die gesamte Dauer des Vorhabens eine Ansprechpartnerin/einen Ansprechpartner für das Gesamtvorhaben zu benennen. Zudem ist eine Vertretung zu benennen, die diese Aufgaben in Abwesenheit dieser Person übernimmt.

6.2 Kostendarstellung

Für die Kalkulation wird darauf hingewiesen, dass der Bearbeitungszeitraum nicht dem tatsächlichen Arbeitsaufwand entspricht, sondern auch Zeiten einschließt, in der die Bearbeitung des Vorhabens ruhen kann.

Die Arbeiten sollen orientierungsmäßig so auf die Laufzeit verteilt werden, dass im Jahr 2024 ca. 25% und im Jahr 2025 ca. 25% und im Jahr 2026 ca. 30% und im Jahr 2027 ca. 20% der Gesamtsumme zu kalkulieren sind.

Die Vergütung wird nach Leistungsfortschritt auf Anforderung gezahlt. Teilzahlungen werden zeitlich an die Vorlage der Zwischen- bzw. Sachstandsberichte gekoppelt. Die Schlusszahlung erfolgt nach Vorlage und Abnahme der endgültigen Fassung des Abschlussberichtes.

Das Angebot ist mit einem detaillierten Zeitplan zu versehen.

Die voraussichtlichen Kosten/Ausgaben der einzelnen Positionen sind durch ein transparentes Preis- und Mengengerüst für Personal- und Sachkosten, ggf. Reisekosten, darzustellen.

Bei Anbietergemeinschaften müssen die Mengen/Kosten einzelner Kooperationspartnerinnen und -partnern den entsprechenden Leistungen so dargestellt werden, dass eine Zuordnung und Bewertung der Mengen/Kosten zu den jeweiligen Arbeitspaketen ermöglicht wird.

Die Kalkulation ist mit Nettobeträgen durchzuführen. Der Gesamtpreis des Angebots ist jeweils als Nettogesamtkosten und Bruttogesamtkosten aufzuführen. Der in Ansatz gebrachte Mehrwertsteuersatz ist gesondert auszuweisen. Hierfür ist das den Vergabeunterlagen beigelegte Preisblatt zu verwenden.

15

7. Eignungskriterien

Die Qualifikation der Anbieter und gegebenenfalls von Kooperationspartnerinnen und -partnern sind durch die Angabe von nachprüfbaren Referenzen in Form von Eigenerklärungen nachzuweisen.

Dazu gehören Kurzinformationen über einschlägige erfolgreich abgeschlossene Projekte /Arbeitsschwerpunkte/Veröffentlichungen oder sonstige Aktivitäten des Auftragnehmers und gegebenenfalls seiner Kooperationspartnerinnen und -partnern in den folgenden Bereichen:

- Kurzinformation zu zwei Referenzprojekten der letzten fünf Jahre, aus denen Erfahrungen im Bereich der Umweltberichterstattung mit einem Datenbezug hervorgehen;
- Kurzinformation zu zwei Referenzprojekten der letzten fünf Jahre, aus denen Erfahrungen in der Entwicklung und Implementierung von ETL-Prozessen hervorgehen
- Kurzinformationen zu zwei Referenzprojekten der letzten fünf Jahre aus denen Erfahrungen im Bereich Umweltstatistik, idealerweise auch Kenntnisse des SDMX-Standards und/oder Erfahrungen mit der .Stat Suite oder vergleichbaren Softwarelösungen hervorgehen;
- Kurzinformation zu zwei Referenzprojekten der letzten fünf Jahre, aus denen Erfahrungen im Bereich Data Science und Datenvisualisierung – insbesondere bei der Erstellung von Dashboards hervorgehen.

- Kurzinformationen zu mindestens zwei Referenzprojekten bzw. entsprechenden Erfahrungen aus dem Bereich KI bzw. des maschinellen Lernens. Idealerweise mit Bezug zu Natural Language Processing (NLP), Natural Language Generation (NLG) bzw. Large Language Modellen (LLM).

Darüber hinaus ist eine kurze Vorstellung der am Vorhaben beteiligten Institutionen und natürlichen Personen sowie der von ihnen im Rahmen des Forschungsvorhabens wahrgenommenen Aufgabe (möglichst Benennung der Bearbeiterinnen und Bearbeiter) dem Angebot beizufügen.

Die Zuverlässigkeit ist durch Unterzeichnung der beigefügten Eigenerklärung zu bestätigen.

Der Anbieter bestätigt mit Abgabe seines Angebotes, dass er über die erforderliche Leistungsfähigkeit verfügt, um das Vorhaben vertragsgemäß bearbeiten zu können.

8. Zuschlagskriterien

Alle Angebote, die den Bewerbungs- und Vertragsbedingungen entsprechen und preislich angemessen sind, werden abschließend vergleichend bewertet. Der Zuschlag wird aufgrund des besten Preis-Leistungsverhältnisses erteilt. Angebote von geeigneten Bietern, deren Angebote inhaltlich vollständig und die notwendigen Nachweise der Fachkunde aufführen, werden anhand folgender Kriterien bewertet:

16

a) Qualität:

Zuschlagskriterien	Maximale Punktzahl	Erforderliche Mindestpunkt-zahl
Übergreifende Kriterien • Projektdesign (v.a. Schlüssigkeit und Ausgewogenheit des Gesamtkonzepts) • Angemessene und erfolgsversprechende Arbeits- und Kostenplanung • Nachvollziehbarkeit des Angebotes	15	8
Die einzelnen Arbeitspakete im Angebot werden grundsätzlich hinsichtlich ihrer Schlüssigkeit, ihres methodischen Ansatzes, der Qualität der gemachten Vorschläge und ihrer Praxistauglichkeit und Verwertbarkeit im Hinblick auf die Zielsetzung des Gesamtprojektes bewertet. Darüber hinaus werden insbesondere die folgenden Kriterien bewertet.		

AP 1	15	7
• Problem und Aufgabenverständnis • Auseinandersetzung mit der Aufgabenstellung und mit dem System des Data Cubes - insbesondere mit der .Stat Suite und SDMX 3.0		
AP 2	15	7
• Praxistauglichkeit und Kreativität der gemachten Vorschläge für die Struktur und Vision des Dashboard-Formates und das Vorgehen zur Entwicklung von Dashboards		
AP 3	15	7
• Problem und Aufgabenverständnis • Inhaltliche Auseinandersetzung mit den Potentialen, Chancen und Risiken beim Einsatz von Modellen des maschinellen Lernens für den Einsatz in der Umweltberichterstattung		
AP 4	10	6
• Auseinandersetzung mit der Problemstellung • Qualität und Innovativität der Ideen für experimentelle Datenprojekte		
Gesamtsumme Qualität	70	35

17

Ein Nichterreichen der Mindestpunktzahl bei mindestens einem Unterkriterium führt zum Ausschluss des Angebots aus der weiteren Wertung.

b) Preis:

Der Angebotsbruttopreis erhält eine Gewichtung von 30%. Die Qualität geht mit 70% in die Bewertung ein.

Preise werden durch die Umrechnung in Punktwerte miteinander ins Verhältnis gesetzt. Die Bewertung des Kriteriums „Preis“ erfolgt nach der folgenden Methode: Das Angebot mit dem niedrigsten Angebotspreis $p_{\min}$ erhält die maximale Preis-Punktzahl (30). Die Preis-Punktzahl N der übrigen Angebote ergibt sich aus dem Produkt aus maximaler Preis-Punktzahl (30) und niedrigstem Angebotspreis $p_{\min}$ im Verhältnis zum Angebotspreis p nach der Formel $N(p)=30 \cdot p_{\min}/p$.

Die erreichten Punkte für die einzelnen Kriterien werden addiert. Das Angebot mit der höchsten Gesamtpunktzahl erhält den Zuschlag.